



Université Paris Cité

Master 2 Mathématiques et Applications
Parcours Mathématiques, Modélisation et Apprentissage Statistique

Rapport de stage

Géométrie des ensembles d'excursion pour l'analyse des extrêmes spatiaux

Stagiaire : Ziqin Ding

Responsables du stage :

Mme Anne Estrade — anne.estrade@u-pariscite.fr

M. José Gregorio Gómez-García —

jose-gregorio.gomez-garcia@u-pariscite.fr

Laboratoire d'accueil :

Laboratoire de Mathématiques Appliquées de Paris 5 (MAP5)

Université Paris Cité – CNRS, UMR 8145

45 rue des Saints-Pères, 75006 Paris

Correspondant du stage à l'UFR :

M. Sylvain Durand - sylvain.durand@u-paris.fr

Année universitaire 2025–2026

Table des matières

1	Résumé	3
2	Présentation du laboratoire MAP5	4
3	Préliminaire : Traitement des données climatiques et outils mathématiques	5
3.1	Données étudiées	5
3.2	Construction de la grille	5
3.3	Projection de l'ensemble des points sur la grille	6
3.4	La distance de Haversine	6
3.5	Tests de stationnarité sur des séries temporelles	6
4	L'ensemble d'excursion en deux dimensions	9
4.1	Choix du seuil	9
4.1.1	Seuil global constant	9
4.1.2	Seuil spatial	9
4.2	Visualisation	9
4.3	Analyse géométrique	10
4.3.1	Nombre de composantes connexes	10
4.3.2	Périmètre	11
4.3.3	Aire	12
4.3.4	Le plus grand disque inclus de l'ensemble d'excursion	13
5	L'ensemble d'excursion en trois dimensions	14
5.1	Analyse mathématique du volume moyen d'excursion	14
5.2	Volume de l'ensemble d'excursion en fonction du niveau et du seuil	15
5.2.1	Le niveau de quantile α	15
5.2.2	Le seuil correspondant $u(\alpha)$	16
6	Transformation vers marges de Pareto standard X^*	17
6.1	Analyse mathématique	17
6.2	Méthodologie : estimation empirique des marges	17
6.3	Lien entre les ensembles d'excursion de X et de X^*	18
6.4	Volume de l'ensemble d'excursion E_{X^*} en fonction du seuil	19
7	Évolution temporelle d'une qualité géométrique	20
7.1	Extraction des séries temporelles	20
7.2	Test de stationnarité	20
7.3	Choix du modèle	21
7.3.1	Modèle AR	22
7.3.2	Extremogramme : Probabilité d'excursion conditionnelle	23
8	QQ plot	25
8.1	Vérification la lois de $X^*(s)$	25
8.2	La tendance de la température chaque été	26
8.3	Validation hors échantillon et classification des étés de test	27
9	Pipeline pour une autre variable : les précipitations	30
9.1	L'ensemble d'excursion de Y en deux dimensions	30
9.2	Séries temporelle de Y^*	30
9.3	QQ plot et validation hors échantillon	32
10	Conclusion et perspectives	36
	Annexes	38

Remerciements

Je tiens tout d'abord à remercier mes encadrants, Mme Anne Estrade et M. José Gregorio Gómez García, pour leur accompagnement, leurs conseils et leur disponibilité tout au long de ce stage.

Je remercie également l'équipe Probabilités et Statistique du laboratoire MAP5 pour son accueil et pour les échanges qui ont contribué au bon déroulement de ce travail.

Enfin, je remercie toutes les personnes qui ont apporté leur aide et leur soutien pendant la réalisation de ce stage.

1 Résumé

Mon stage a été réalisé au sein de l'équipe Probabilités et Statistique du laboratoire MAP5, sous la direction de Mme Anne Estrade et de M. José Gregorio Gomez Garcia. Ce travail porte sur l'étude des champs aléatoires spatio-temporels, avec un intérêt particulier pour les événements extrêmes. Ceux-ci peuvent présenter des structures spatiales variées, allant de zones isolées à des régions étendues et connexes [1, 2, 3].

Nous analysons leur extension spatiale à partir des ensembles d'excursion associés à différents seuils. Nous nous intéressons aux propriétés géométriques de ces ensembles, telles que leur aire, leur périmètre, leur nombre de composantes connexes et leur rayon inscrit maximal. Une transformation marginale vers des marges de Pareto standard est ensuite utilisée afin de faciliter l'analyse des événements extrêmes.

L'évolution temporelle des caractéristiques géométriques obtenues est étudiée à l'aide de méthodes adaptées aux séries temporelles. Les résultats indiquent que la plupart de ces séries sont stationnaires et présentent une dépendance temporelle à court terme. L'extrémogramme est également utilisé pour analyser la persistance des événements de grande extension spatiale. Enfin, la méthode est appliquée à des données de précipitation afin d'évaluer la transformation marginale sur un autre jeu de données et dans un cadre de validation hors échantillon.

2 Présentation du laboratoire MAP5

Ce stage a été réalisé au sein du Laboratoire de Mathématiques Appliquées à Paris 5 (MAP5), une unité mixte de recherche de l'Université Paris Cité et du Centre National de la Recherche Scientifique (CNRS). Le laboratoire est également rattaché à l'Institut National des Sciences Mathématiques et de leurs Interactions (INSMI) du CNRS et membre de la Fondation Sciences Mathématiques de Paris (FSMP).

Le MAP5 mène des recherches en mathématiques appliquées, avec des travaux portant notamment sur les probabilités, la statistique, la modélisation, l'analyse, la simulation et les mathématiques pour l'image. Ces différents domaines permettent de développer des méthodes mathématiques adaptées à des problèmes provenant de plusieurs disciplines scientifiques.

Ce travail s'inscrit dans les thématiques du MAP5, en particulier dans l'étude des processus aléatoires et la modélisation statistique de phénomènes environnementaux.

3 Préliminaire : Traitement des données climatiques et outils mathématiques

3.1 Données étudiées

Dans un premier temps, nous téléchargeons des données climatiques atmosphériques depuis le site <https://www.drias-climat.fr>. Nous choisissons des données corrigées issues de DRIAS 2020, basées sur le modèle CNRM-CERFACS-CNRM-CM5 / CNRM-ALADIN63.

Afin de réaliser nos travaux, on sélectionne des données couvrant la période 1986–2005, correspondant aux températures maximales (en degrés °C) d’été (juin, juillet et août) sur la France métropolitaine, comprenant 8813 points d’observation. Le jeu de données contient 4 colonnes, qui présentent la date, la latitude et la longitude, ainsi que la valeur de température associée.

Dans le cadre de ce travail, les données sont ensuite nettoyées afin d’assurer leur cohérence. Les valeurs manquantes pour la température sont identifiées et traitées comme des valeurs *NA*. On crée une colonne $c \in \{1, 2, \dots, 8813\}$ en plus qui représente l’identifiant de chaque localisation.

On construit ensuite le modèle mathématique : Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité. Soit $X : \mathbb{R}^2 \times [0, T] \times \Omega \rightarrow \mathbb{R}$ un champ aléatoire défini sur $\mathbb{R}^2 \times [0, T]$. Soit $D \subset \mathbb{R}^2$ un sous-ensemble de $\mathbb{R}^2$, qui représente le domaine spatial et $[0, T] \subset \mathbb{R}$ un ensemble du temps, qui représente chaque date, et T est le nombre de jours observés.

3.2 Construction de la grille

On souhaite construire une grille régulière afin de représenter les points sur une carte. On commence par déterminer l’emprise spatiale du domaine à partir de l’ensemble de localisation (latitude, longitude) de tous les points observés $D \subset \mathbb{R}^2$, en extrayant les bornes en latitude $[\phi_{\min}, \phi_{\max}] = [42.35, 51.05]$ et en longitude $[\lambda_{\min}, \lambda_{\max}] = [-4.96, 8.18]$. À partir d’une résolution fixée $\delta = 0.1$, exprimée en degrés, on en déduit les dimensions de la grille :

$$n_{\text{rows}} = \left\lceil \frac{\phi_{\max} - \phi_{\min}}{\delta} \right\rceil + 1 = 88, \quad n_{\text{cols}} = \left\lceil \frac{\lambda_{\max} - \lambda_{\min}}{\delta} \right\rceil + 1 = 132,$$

où $\lceil \cdot \rceil$ désigne l’arrondi à l’entier le plus proche. Les latitudes des lignes sont réparties uniformément de $\phi_{\max}$ à $\phi_{\min}$, de sorte que la première ligne de la grille corresponde au Nord.

Comme la résolution δ est exprimée en degrés, on convertit les distances en kilomètres afin de tenir compte de la géométrie terrestre. Sachant que le périmètre de la terre au niveau de l’équateur est 40075 km, une distance de 1° sur la surface de la terre est donnée par $40075 \text{ km} / 360 \approx 111,32 \text{ km}$. Donc dans le sens Nord–Sud, la distance entre deux parallèles est constante :

$$d_{\text{NS}} = \delta \times 111,32 \text{ km}. \quad (1)$$

En revanche, dans le sens Est–Ouest, la distance dépend de la latitude ϕ , car la distance entre deux méridiens diminue vers les pôles. Ainsi, mesurer une distance selon la direction Est–Ouest revient à considérer le rayon du parallèle situé à la latitude ϕ :

$$d_{\text{EO}}(i) = \delta \times 111,32 \times \cos(\phi_i) \text{ km}. \quad (2)$$

où ϕ_i est la latitude de ligne i de la grille. En effet, le domaine d’étude couvre une étendue en latitude supérieure à 8,7°. Sur une telle plage, le facteur $\cos(\phi)$ varie de façon non

négligeable entre le Sud et le Nord du domaine, la distance d_{EO} est calculée ligne par ligne, en fonction de la latitude propre à chaque ligne.




FIGURE 1 – Grille de latitude et longitude sur une sphère

Source : <https://en.wikipedia.org/wiki/Latitude>

L'ensemble de ces informations (bornes spatiales, dimensions de la grille, distances métriques) est regroupé dans une structure de métadonnées **meta**, réutilisée ensuite dans les fonctions d'analyse afin de garantir une construction cohérente de la grille à travers tous les calculs.

3.3 Projection de l'ensemble des points sur la grille

Soit $S = \{x_1, \dots, x_N\} \subset D$ un sous-ensemble de $\mathbb{R}^2$, on souhaite le projeter dans la grille régulière **meta**. On construit une grille binaire $G \in \{0, 1\}^{n_{\text{rows}} \times n_{\text{cols}}}$, où $G_{rc} = 1$ si au moins un point de S tombe dans la cellule (r, c) , c'est-à-dire

$$G_{rc} = \mathbf{1}\{\kappa^{-1}(r, c) \neq \emptyset\},$$

où κ désigne l'application qui projette $x_i \in S$ vers la grille :

$$\kappa : i \in \{1, \dots, N\} \mapsto \kappa(i) = (r, c) \quad \text{si } x_i \in \text{cellule } (r, c)$$

Chaque cellule est seuillée à 1, ce qui gère naturellement le cas où plusieurs points sont rattachés à la même cellule. Parallèlement, pour chaque cellule occupée, on mémorise la liste des indices des points qui s'y projettent.

3.4 La distance de Haversine

La distance Haversine est la distance angulaire entre deux points à la surface d'une sphère. La première coordonnée de chaque point est supposée être la latitude, la seconde la longitude, toutes deux exprimées en radians. Elle est définie par :

$$d(s, s') = 2 \arcsin \left(\sqrt{\sin^2 \left(\frac{s_{\text{lat}} - s'_{\text{lat}}}{2} \right) + \cos(s_{\text{lat}}) \cos(s'_{\text{lat}}) \sin^2 \left(\frac{s_{\text{lon}} - s'_{\text{lon}}}{2} \right)} \right) \quad (3)$$

on utilise la fonction `haversine_distances` du package `sklearn.metrics.pairwise` pour calculer la distance Haversine entre deux points s et s' .

3.5 Tests de stationnarité sur des séries temporelles

Dans le chapitre 6, nous étudierons les séries temporelles obtenues à partir des indicateurs géométriques (aire, périmètre, etc.) de l'ensemble d'excursion. L'objectif est d'analyser leur stationnarité temporelle, nous présentons donc ici deux tests de stationnarité utilisés dans la suite : le test ADF (Dickey-Fuller augmenté) [4] et le test KPSS [5].

Soit $(X_t)_{t \in \mathbb{Z}}$ un processus stochastique à temps discret, dont nous observons une trajectoire $(x_1, \dots, x_T)$.

Rappelons que (X_t) est dit *stationnaire au second ordre* (ou faiblement stationnaire) si son espérance est constante au cours du temps et si sa covariance est invariante par translation temporelle :

$$\mathbb{E}[X_t] = \mu, \quad \text{Cov}(X_s, X_t) = \text{Cov}(X_{s+h}, X_{t+h}), \quad \forall s, t, h \in \mathbb{Z}.$$

Afin de tester cette propriété sur nos séries, nous utilisons conjointement deux tests classiques de stationnarité.

Test de Dickey–Fuller augmenté (ADF). Le test de Dickey–Fuller augmenté (ADF) [4] est utilisé afin de déterminer si une série temporelle est stationnaire ou non, il repose sur une régression auxiliaire de la forme :

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \varepsilon_t$$

où Δy_t représente la variation de la série entre deux périodes. Les termes retardés Δy_{t-i} sont ajoutés afin de corriger l'autocorrélation éventuelle des résidus. Le coefficient γ constitue le paramètre d'intérêt du test. En effet, cette formulation provient d'un modèle autorégressif de premier ordre :

$$y_t = \rho y_{t-1} + \varepsilon_t,$$

qui peut être réécrit sous la forme :

$$\Delta y_t = (\rho - 1)y_{t-1} + \varepsilon_t.$$

Ainsi, on définit $\gamma = \rho - 1$. Lorsque $\gamma = 0$, on obtient $\rho = 1$, ce qui correspond à la présence d'une racine unitaire :

$$y_t = y_{t-1} + \varepsilon_t.$$

Dans ce cas, les effets des chocs passés persistent indéfiniment et la série est non stationnaire. À l'inverse, lorsque $\gamma < 0$, on a $\rho < 1$, ce qui signifie que l'influence des valeurs passées diminue progressivement et que la série tend à revenir vers un niveau stable.

Dans ce travail, le test ADF est réalisé à l'aide de la fonction `adfuller` du package `statsmodels.tsa.stattools`.

Les hypothèses du test sont :

$$H_0 : \gamma = 0 \text{ (série non stationnaire)} \quad \text{contre} \quad H_1 : \gamma < 0 \text{ (série stationnaire)}.$$

La décision repose sur la p-valeur ou sur la statistique ADF associée au coefficient γ . Si la p-valeur est inférieure à 5%, l'hypothèse nulle est rejetée et la série est considérée comme stationnaire. Dans le cas contraire, on conclut que la série présente une non-stationnarité.

Test KPSS. Le test KPSS [5] adopte la démarche inverse : la stationnarité constitue cette fois l'hypothèse nulle. La série est décomposée en la somme d'une tendance déterministe, d'une marche aléatoire et d'une erreur stationnaire :

$$y_t = \beta t + r_t + \varepsilon_t, \quad r_t = r_{t-1} + u_t, \quad u_t \sim \text{iid}(0, \sigma_u^2),$$

où (r_t) est la composante de marche aléatoire et (ε_t) un processus stationnaire. Les hypothèses s'écrivent

$$H_0 : \sigma_u^2 = 0 \text{ (série stationnaire)} \quad \text{contre} \quad H_1 : \sigma_u^2 > 0 \text{ (série non stationnaire)}.$$

En effet, si $\sigma_u^2 = 0$, la composante r_t est constante et y_t est stationnaire (autour d'une tendance si $\beta \neq 0$). On ne rejette donc pas H_0 lorsque la p -valeur est supérieure à α .

Le test KPSS est réalisé à l'aide de la fonction `kpss` du package `statsmodels.tsa.stattools`.

Lecture conjointe des deux tests. L'utilisation conjointe des deux tests permet une conclusion plus robuste, selon la grille de lecture suivante :

- ADF rejette H_0 et KPSS ne rejette pas H_0 : les deux tests concordent, la série est stationnaire ;
- ADF ne rejette pas H_0 et KPSS rejette H_0 : les deux tests concordent, la série est non stationnaire et doit être différenciée avant modélisation ;
- conclusions contradictoires : la série peut être trend-stationnaire, ou l'échantillon trop court pour trancher ; un examen complémentaire (différenciation, retrait de tendance) est alors nécessaire.

4 L'ensemble d'excursion en deux dimensions

Dans ce chapitre, nous étudions l'ensemble d'excursion E_X pour une date t fixée dans $[0, T]$, c'est-à-dire,

$$E_X(u, t) = \{s \in D \mid X(s, t) > u\}.$$

4.1 Choix du seuil

Rappelons que pour $u \in \mathbb{R}$, on définit l'ensemble d'excursion de X pour un seuil u :

$$E_X(u) = \{s \in D, t \in [0, T] \mid X(s, t) > u\}.$$

Au cours de nos travaux, deux types de seuil sont employés : le seuil global constant et le seuil spatial.

4.1.1 Seuil global constant

On peut choisir un seuil identique pour toutes les localisations $s \in D$ et toutes les dates $t \in [0, T]$. Pour chaque niveau $\alpha \in [0, 1]$, le quantile empirique de niveau α est alors calculé sur l'ensemble des valeurs de X :

$$u(\alpha) = \widehat{q}_\alpha(\{X(s, t) : s \in D, t \in [0, T]\}).$$

4.1.2 Seuil spatial

On peut définir également une fonction de seuil spatial. Pour chaque localisation $s \in D$, elle renvoie le quantile empirique d'ordre $\alpha \in [0, 1]$ de la distribution des valeurs $\{X(s, t) : t \in [0, T]\}$, c'est-à-dire l'ensemble des températures observées en ce point s sur toutes les dates de la période d'étude, il s'écrit comme

$$u(\alpha, s) = \widehat{q}_\alpha(\{X(s, t) : t \in [0, T]\}), \quad \text{pour chaque } s \in D$$

En appliquant ce seuil à toutes les localisations $s \in D$, on obtient un vecteur de seuils $U(\alpha) = (u(\alpha, s))_{s \in D}$, contenant le seuil de chaque point du domaine.

TABLE 1 – Seuil spatial : les 5 premières positions selon l'ordre des identifiants.

id	$u(\alpha = 0.95, s)$
1	23.3010
2	22.0315
3	26.2920
4	27.8310
5	28.7500

Ce seuil, propre à chaque localisation, représente le niveau d'extrême local : il s'adapte à la climatologie de chaque point de la grille plutôt que d'imposer un seuil uniforme sur l'ensemble du domaine.

4.2 Visualisation

L'idée est que pour une date donnée, tous les points observés sont présentés en couleur gris, tandis que les points appartenant à l'ensemble d'excursion sont en rouge. Les deux types de seuil sont appliqués ici.




FIGURE 2 – l'ensemble d'excursion de X pour un seuil spatial $u(0.95, s)$ en 2001-08-09

Seuil constant La première approche consiste à prendre un seuil global constant au niveau 95%, $u(0.95) = \widehat{q}_{0.95}(\{X(s, t) : s \in D, t \in [0, T]\})$. On trace alors l'ensemble d'excursion de $X(t)$ au-dessus de ce seuil, en deux dimensions, à la date t :

$$E_X(0.95, t) = \{s \in D : X(s, t) > u(0.95)\}.$$

Seuil spatial On définit alors l'ensemble d'excursion au-dessus du seuil spatial $U(0.95)$, à l'instant t , par

$$E_X(U(0.95), t) = \{s \in D : X(s, t) > U(0.95)\},$$

4.3 Analyse géométrique

Nous introduisons 4 indicateurs pour caractériser l'ensemble d'excursion $E_X(u, t)$ pour une date t donnée – le nombre de composantes connexes, la périmètre, l'aire, et le plus grand disque inclus dans l'ensemble d'excursion. On rappelle que pour chaque $t \in [0, T]$, l'ensemble d'excursion de X pour un seuil u est

$$E_X(u, t) = \{s \in D \mid X(s, t) > u\},$$

et toutes les opérations sont appliquées sous la grille construite dans 3.2 et la méthode de la projection construite dans 3.3. Pour la suite de cette section, on considère que t est fixé dans $[0, T]$.

4.3.1 Nombre de composantes connexes

Une *composante connexe* de $E_X(u)$ est un sous-ensemble maximal $C \subseteq E_X(u)$ vérifiant les deux propriétés suivantes :

1. **Connexité** : pour tout couple de points $x, y \in C$, il existe un chemin entre x et y : $x = x_0 \rightarrow x_1 \rightarrow \dots \rightarrow x_k = y$ tel que $x_i \in C$ pour tout i et x_i, x_{i+1} soient voisins ;
2. **Maximalité** : C n'est strictement contenu dans aucun autre sous-ensemble connexe de $E_X(u)$.

Deux types de connexité sont généralement considérées : la 4-connexité, qui ne retient que les voisins partageant un côté, et la 8-connexité, qui inclut également les voisins diagonaux.

0	1	0
1	1	1
0	1	0

FIGURE 3 – 4-connexité

1	1	1
1	1	1
1	1	1

FIGURE 4 – 8-connexité

On fixe un système de voisinage $\mathcal{V} \subset \mathbb{Z}^2 \setminus \{(0,0)\}$, symétrique au sens où $\mathcal{V} = -\mathcal{V}$:

$$\mathcal{V}_4 = \{(0, \pm 1), (\pm 1, 0)\}, \quad \mathcal{V}_8 = \mathcal{V}_4 \cup \{(\pm 1, \pm 1)\}, \quad (4)$$

correspondant respectivement à la 4-connexité et à la 8-connexité.

On construit ensuite le graphe non orienté $G_E = (E, \mathcal{E})$ de sommets $E = \{1, \dots, N\}$ et d'ensemble d'arêtes

$$\mathcal{E} = \{ \{i, j\} : i \neq j, \quad \kappa(i) - \kappa(j) \in \mathcal{V} \cup \{(0,0)\} \}, \quad (5)$$

autrement dit : deux points sont voisins si et seulement s'ils se projettent dans la même cellule, ou dans deux cellules voisines au sens de $\mathcal{V}$.

L'algorithme parcourt les cellules occupées $(r, c) \in E_X(u, t)$ et engendre les arêtes en deux familles :

1. *Cas $\kappa(i) = \kappa(j)$ (clique intra-cellule)* : Les deux points sont dans la même cellule.
2. *Cas $\kappa(i) - \kappa(j) \in \mathcal{V}$ (arêtes inter-cellules)* : Les deux points sont voisins au sens de $\mathcal{V}$.

Étiquetage des composantes connexes Les composantes connexes de $G_{\mathcal{V}}$ sont extraites par l'algorithme `connected_components` de `scipy.sparse.csgraph`.

L'opération est effectuée séparément pour $\mathcal{V}_4$ et $\mathcal{V}_8$, fournissant deux étiquetages stockés dans les colonnes `comp4` et `comp8` (identifiants numérotés à partir de 1), ainsi que les nombres de composantes n_4 et n_8 .

Le cas dégénéré d'un ensemble d'excursion vide ($N = 0$) est traité explicitement et renvoie $n_4 = n_8 = 0$.

En pratique, nous choisissons aléatoirement une date, le 9 août 2001, et considérons l'ensemble d'excursion associé au seuil spatial $u(0.95, s)$. Nous obtenons $n_4 = 24$, contre $n_8 = 12$ (figure 5).

4.3.2 Périmètre

Le périmètre de l'ensemble d'excursion est défini comme la longueur totale de la frontière de l'union des cellules occupées.

Contrairement à l'étiquetage des composantes, le calcul du périmètre ne fait intervenir aucune structure de graphe sur les points : il s'applique uniquement sur la grille binaire d'occupation G . Que plusieurs points se projettent dans une même cellule ou dans des cellules distinctes est sans incidence, seule compte le contour des cellules occupées, et le périmètre se réduit au décompte des arêtes de cellules séparant une cellule occupée d'une cellule vide.

Chaque arête est convertie en kilomètres selon son orientation : une arête séparant deux colonnes adjacentes est un segment Nord-Sud de longueur constante d_{NS} , tandis qu'une




FIGURE 5 – Nombre de composantes connexes pour une 4-connectivité (à gauche) et une 8-connectivité (à droite) en 2001-08-09

arête séparant deux lignes adjacentes est un segment Est–Ouest de longueur $d_{EO}(\phi_r)$, évaluée à la latitude de la ligne concernée, selon la définition donnée dans la section 2.2.

Le périmètre de l’excursion $E_X(u)$ s’écrit donc

$$P = n_{NS} \cdot d_{NS} + \sum_i n_{EO}(i) d_{EO}(\phi_i), \quad (6)$$

où n_{NS} est le nombre total d’arêtes Nord–Sud frontières et $n_{EO}(i)$ le nombre d’arêtes Est–Ouest frontières associées à la ligne i . Ces décomptes sont obtenus de façon vectorisée en repérant les transitions $0 \leftrightarrow 1$ entre cellules voisinage (`np.diff` selon chaque axe), auxquelles s’ajoutent les cellules occupées touchant les quatre bords du domaine. Par convention, une arête interne séparant les lignes i et $i + 1$ est affectée de la longueur de la ligne supérieure $d_{EO}(\phi_i)$, approximation négligeable à la résolution considérée.

A l’aide de l’ensemble d’excursion présenté dans la figure 5, nous obtenons que un périmètre totale de 8603.5km.

4.3.3 Aire

Dans un modèle supposé continu en espace, l’aire de l’ensemble d’excursion, selon la mesure de Lebesgue, s’écrit

$$\text{Aire}(E_X(u, t)) = \int_D \mathbf{1}_{\{X(s, t) > u\}} ds. \quad (7)$$

On obtient alors

$$\mathbb{E}(\text{Aire}(E_X(u, t))) = \int_D \mathbb{P}(X(s, t) > u) ds. \quad (8)$$

Cette quantité dépend en général de s . Si $X(\cdot, t)$ est spatialement stationnaire, alors $\mathbb{P}(X(s, t) > u)$ est indépendant de s et

$$\mathbb{E}(\text{Aire}(E_X(u, t))) = \mathbb{P}(X(s, t) > u) \times \text{Aire}(D). \quad (9)$$

Sur les données réelles, le champ n’est pas a priori pas stationnaire, on considère un seuil spatialement variable $u(\alpha, s)$.

Sur une grille discrète, l’aire empirique de l’ensemble d’excursion est estimée par

$$\widehat{\text{Aire}}(E_X(u, t)) = \sum_{r,c} \mathbb{1}_{(r,c) \in E_X(u,t)} \times \text{aire}(\text{cellules}(r,c)) \quad (10)$$

$$= \sum_{r=1}^{n_{\text{rows}}} \sum_{c=1}^{n_{\text{cols}}} \mathbb{1}_{\{X_{r,c}(t) \geq u_{r,c}\}} d_{\text{NS}} d_{\text{EO}}(r) \quad (11)$$

$$= d_{\text{NS}} \sum_{r=1}^{n_{\text{rows}}} n_r d_{\text{EO}}(r), \quad (12)$$

où n_r désigne le nombre de cellules de la ligne r appartenant à l'ensemble d'excursion.

Lorsque l'ensemble d'excursion se décompose en plusieurs composantes connexes $E_X(t)(u) = \bigsqcup_{k=1}^K C_k$, l'aire de chaque composante est estimée séparément par :

$$\widehat{\text{Aire}}(C_k) = d_{\text{NS}} \sum_{r=1}^{n_{\text{rows}}} n_r^{(k)} \cdot d_{\text{EO}}(r) \quad (13)$$

où $n_r^{(k)}$ désigne le nombre de cellules de la composante C_k sur la ligne r de la grille.

À l'aide de l'ensemble d'excursion présenté dans la figure 5, nous obtenons une aire totale de 220,116,4 km², correspondant à 2,537 cellules.

4.3.4 Le plus grand disque inclus de l'ensemble d'excursion

Commençons par trouver le rayon maximal inscrit d'un point s appartenant à l'ensemble d'excursion. Pour chaque point $s \in E_X(u)$, on définit le rayon maximal inscrit comme le rayon de la plus grande boule centrée en s contenue dans l'ensemble d'excursion $E_X(u)$:

$$r(s) = \min_{s' \in E_X^c(u)} d(s, s') \quad (14)$$

où $d(\cdot, \cdot)$ désigne la distance euclidienne dans le cas continu, et $E_X^c(u) = D \setminus E_X(u)$.

Le rayon inscrit maximal de l'ensemble d'excursion est alors :

$$r^*(E_X(u)) = \max_{s \in E_X(u)} r(s) \quad (15)$$

Lorsque $E_X(u)$ se décompose en plusieurs composantes connexes $E_X(u) = \bigsqcup_{k=1}^K C_k$, on calcule le rayon inscrit maximal de chaque composante séparément :

$$r^*(C_k) = \max_{s \in C_k} r(s), \quad k = 1, \dots, K \quad (16)$$

Le rayon global $r^*(E_X(u)) = \max_k r^*(C_k)$ caractérise alors la composante la plus grande de l'ensemble d'excursion.

En pratique, l'ensemble d'excursion étant observé sur une grille spatiale discrète, le calcul est effectué de manière vectorisée : on évalue la matrice des distances Haversine entre tous les points de $E_X(u)$ et tous les points du complémentaire $E_X^c(u)$. Pour chaque point discret $s_i \in E_X(u)$, on estime alors le rayon inscrit par :

$$\hat{r}(s_i) = \min_{s_j \in E_X^c(u)} d(s_i, s_j).$$

Comme présenté dans la figure 6, le rayon inscrit maximal de l'ensemble d'excursion de X pour le seuil $u(0.95, s)$ est 178,3 km. Il est centré au point d'identifiant 791, situé dans la plus grande composante connexe.




FIGURE 6 – Approximation discrète du plus grand disque inscrit de l'ensemble d'excursion, trié par composantes connexes de 4-connexité




FIGURE 7 – Exemple d'ensemble d'excursion spatio-temporel pour les températures dépassant le seuil $u(0.95, s)$ dans l'année 1988.

5 L'ensemble d'excursion en trois dimensions

Nous cherchons à représenter graphiquement les ensembles d'excursion $E_X(u) = \{s \in D, t \in [0, T] \mid X(s, t) > u\}$ en trois dimensions, c'est-à-dire en fonction des coordonnées spatiales (latitude et longitude) et du temps.

Les axe x et l'axe y représentent des données spatiales, l'axe z est vu comme l'axe du temps. Pour chaque couche $t \in [0, T]$, on trace seulement les points qui appartient à l'ensemble d'excursion $E_X(u, t)$. La graphe est obtenue en appliquant les données estivales d'une année au hasard (juin, juillet et août). Afin de faciliter l'interprétation géographique, les frontières de la France métropolitaine sont également représentées sur le graphique.

5.1 Analyse mathématique du volume moyen d'excursion

Supposons que X soit un champ aléatoire stationnaire. Par stationnarité, la loi de $X(s, t)$ ne dépend pas de (s, t) .

Ainsi, la probabilité de dépassement d'un seuil u est indépendante de (s, t) et s'écrit :

$$\bar{\phi}(u) = \mathbb{P}(X(s, t) > u).$$

En considérant l'ensemble d'excursion de X dans un modèle continu en espace et en temps :

$$E_X(u) = \{(s, t) \in D \times [0, T] : X(s, t) > u\},$$

son volume est donné par :

$$\text{Vol}(E_X(u)) = \int_{D \times [0, T]} \mathbb{1}_{\{X(s, t) > u\}} \, ds \, dt.$$

En prenant l'espérance et en utilisant la stationnarité de X , on obtient :

$$\begin{aligned} \mathbb{E} [\text{Vol}(E_X(u))] &= \int_{D \times [0, T]} \mathbb{P}(X(s, t) > u) \, ds \, dt \\ &= \text{Vol}(D \times [0, T]) \bar{\phi}(u) \quad \text{par stationnarité} \\ &= T \times \text{aire}(D) \bar{\phi}(u). \end{aligned}$$

Ainsi, après normalisation par le volume du domaine, on obtient :

$$\frac{\mathbb{E} [\text{Vol}(E_X(u))]}{T \times \text{aire}(D)} = \bar{\phi}(u)$$

5.2 Volume de l'ensemble d'excursion en fonction du niveau et du seuil

Dans cette partie, on calcule le volume normalisé de l'ensemble d'excursion, puis on trace son évolution en fonction du **niveau de quantile** α ainsi que du **seuil correspondant** $u(\alpha)$.

Sur données réelles, le volume d'excursion empirique normalisé est défini par :

$$\bar{V} = \frac{|E_u|}{n_{\text{temps}} \times n_{\text{spatial}}}$$

où $|E_u|$ désigne ici la cardinalité de l'ensemble E_u , c'est-à-dire le nombre de points de la grille spatio-temporelle appartenant à l'ensemble d'excursion.


5.2.1 Le niveau de quantile α

Pour le seuil constant comme pour le seuil spatial, on observe que le graphique en fonction du niveau de quantile α est toujours une droite décroissante. En effet, par la définition du seuil constant $u(\alpha) = \hat{q}_\alpha(X(s, t), s \in D, t \in [0, T])$ le volume d'excursion empirique normalisé s'écrit :


$$\begin{aligned} \hat{V}(\alpha) &= \frac{\widehat{\text{Vol}}(E_X(u(\alpha)))}{\text{Vol}(D \times [0, T])} \\ &= \frac{\sum_{(s, t) \in D \times [0, T]} \mathbb{1}_{\{X(s, t) > u(\alpha)\}}}{\#(D \times [0, T])} \\ &= 1 - \alpha, \quad \text{par définition de } u(\alpha) := \hat{q}_\alpha(X(s, t), s \in D, t \in [0, T]). \end{aligned}$$

Parallèlement, pour le seuil spatial, on a

$$\begin{aligned} \hat{V}(\alpha) &= \frac{\widehat{\text{Vol}}(E_X(u(\alpha)))}{\text{Vol}(D \times [0, T])} \\ &= \frac{\sum_{(s, t) \in D \times [0, T]} \mathbb{1}_{\{X(s, t) > u(\alpha, s)\}}}{\#(D) \times \#([0, T])} \\ &= \frac{1}{\#(D)} \sum_{s \in D} \underbrace{\left(\frac{\sum_{t \in [0, T]} \mathbb{1}_{\{X(s, t) > u(\alpha, s)\}}}{\#([0, T])} \right)}_{= 1 - \alpha \text{ pour chaque } s} = 1 - \alpha. \end{aligned}$$



(a) Volume d'excursion en fonction du niveau de quantile α pour X avec un seuil constant, X_{gaussien} avec un seuil constant et X avec un seuil spatial.



(b) Comparaison du volume d'excursion de X et de X_{gaussien} en fonction du seuil constant $u(\alpha)$.

FIGURE 8 – Comparaison du volume d'excursion selon deux représentations : en fonction du niveau de quantile α et en fonction du seuil constant $u(\alpha)$.

Ce qui confirme la relation linéaire décroissante, observée sur le graphique de gauche de la Fig 8a.

Pour disposer d'un cas de référence, nous générons une variable gaussienne X_{gaussien} de même moyenne et de même variance que les données observées X :

$$X_{\text{gaussien}} \sim \mathcal{N}(\mu_X, \sigma_X^2).$$

La courbe en fonction de α est pareille que celle de X , puisque le volume d'excursion vaut $1 - \alpha$ dans les deux cas.

5.2.2 Le seuil correspondant $u(\alpha)$

On trace ensuite le graphe de $(u(\alpha), \hat{V}(\alpha))$ pour α variant de 0 à 1. Pour le seuil constant $u(\alpha)$, le volume d'excursion devient :

$$V(u(\alpha)) = \mathbb{P}(X(s, t) > u(\alpha)) = 1 - \hat{F}(u(\alpha))$$

où F désigne la fonction de répartition de X .

La figure 8b compare les volumes d'excursion de X et de X_{gaussien} en fonction du seuil $u(\alpha)$. Les deux courbes sont globalement proches, ce qui indique que la distribution empirique de X est proche du cas gaussien sur une grande partie des valeurs observées.

Il est impossible de tracer le graphe en fonction de u_s , car le seuil u_s dépend non seulement de α mais également de la localisation s et varie d'un point à l'autre, rendant toute représentation univariée impossible. Pour s'affranchir de cette dépendance spatiale, on cherche à appliquer une transformation marginale : chaque série temporelle $\{X(s, t) : t \in [0, T]\}$ est transformée de sorte que toutes les lois marginales soient identiques, éliminant ainsi l'effet de la position spatiale s . On peut alors définir un seuil constant x sur le domaine transformé et étudier le volume d'excursion en fonction de ce seuil unique. Cette transformation est présentée dans la chapitre suivant.

6 Transformation vers marges de Pareto standard X^*

6.1 Analyse mathématique

Hypothèse. Nous supposons que X est stationnaire en temps. Cette hypothèse sera vérifiée dans la section 6.2.

Rappelons que X est un processus aléatoire à valeurs dans $\mathbb{R}$, défini sur un espace spatio-temporel $D \times [0, T]$.

Pour une position fixe $s \in D$, la projection $X(s, \cdot)$ est une variable aléatoire dont la distribution est appelée **loi marginale** du processus en s . On note F_s sa fonction de répartition, définie par :

$$F_s(x) = \mathbb{P}(X(s) \leq x)$$

En pratique, un processus aléatoire non contraint peut présenter des lois marginales hétérogènes (par exemple, une loi normale en un point s_1 et une loi exponentielle en un point s_2). Cette hétérogénéité rend complexe l'étude pure de la structure de dépendance spatiale ou temporelle du processus.

Pour pallier cette difficulté, on introduit un nouveau processus aléatoire X^* , défini ponctuellement pour tout $s \in D$ par la transformation suivante :

$$X^*(s) = \frac{1}{1 - F_s(X(s))}$$

et on étudie la loi de $X^*(s)$. Comme F_s est à valeur dans $[0, 1[$, $X^* \in]1, +\infty]$ p.s. Pour $x > 1$:

$$\begin{aligned} \mathbb{P}(X^*(s) > x) &= \mathbb{P}\left(\frac{1}{1 - F_s(X(s))} > x\right) \\ &= \mathbb{P}\left(1 - F_s(X(s)) < \frac{1}{x}\right) \\ &= \mathbb{P}\left(F_s(X(s)) > 1 - \frac{1}{x}\right) \\ &= \mathbb{P}\left(X(s) > F_s^{-1}\left(1 - \frac{1}{x}\right)\right) \\ &= 1 - F_s\left(F_s^{-1}\left(1 - \frac{1}{x}\right)\right) = \frac{1}{x}, \end{aligned} \tag{17}$$

où l'on a utilisé la continuité et la stricte croissance de F_s . Ainsi $X^*(s)$ suit une loi de Pareto standard $\text{Pa}(1)$, de fonction de survie $\bar{F}(x) = \frac{1}{x} \mathbb{1}_{\{x \geq 1\}} + \mathbb{1}_{\{x < 1\}}$.

6.2 Méthodologie : estimation empirique des marges

Bien que on ait analysé X^* théoriquement, en pratique, on ne connaît pas la loi de répartition F_s , donc on cherche à l'estimer.

Dans notre implémentation, la transformation des observations vers des marges de Pareto standard s'effectue de manière indépendante pour chaque position. Soit un échantillon d'observations $x = (x_1, \dots, x_n)$ de taille n (correspondant à l'historique des températures d'une station spécifique).

Nous cherchons l'estimateur de la fonction de répartition empirique (entre 1986-2005), noté $\widehat{F}_s$ pour chaque station s , il s'appuie sur le calcul des rangs pour des raisons d'efficacité.

Pour chaque observation x_i , on détermine son rang r_i au sein de l'échantillon local (classé par ordre croissant). En présence d'ex-aequo (valeurs de température identiques), la




FIGURE 9 – Comparaison entre l'ensemble d'excursion de X pour un seuil spatial et celle de X^* pour un seuil constant au même niveau.

méthode de la moyenne leur est appliquée afin de garantir une symétrie dans le classement. L'estimateur de la fonction de répartition est alors défini par :

$$\widehat{F}_s(x_i) = \frac{r_i}{n+1}$$

Il convient de noter l'utilisation du terme $n+1$ au lieu de n . En effet, elle garantit que $\widehat{F}_s(x_i) < 1$ pour le maximum de l'échantillon.

La valeur transformée $X_i^*(s)$ est obtenue par la relation :

$$X_i^*(s) = \frac{1}{1 - \widehat{F}_s(x_i)}$$

6.3 Lien entre les ensembles d'excursion de X et de X^*

La transformation marginale de Pareto préserve la géométrie des ensembles d'excursion : le dépassement d'un seuil spatialement hétérogène par le champ initial X équivaut au dépassement d'un seuil constant par le champ transformé X^* . La proposition suivante formalise cette propriété.

Proposition 6.1. *Soit $X = \{X(s), s \in D\}$ un champ aléatoire dont les fonctions de répartition marginales F_s sont continues et strictement croissantes pour tout $s \in D$. On définit le champ transformé*

$$X^*(s) = \frac{1}{1 - F_s(X(s))}, \quad s \in D,$$

de sorte que $X^*(s) \sim \text{Pa}(1)$ pour tout $s \in \mathcal{D}$. Alors, pour tout niveau $\alpha \in (0, 1)$,

$$E_X(u(\cdot; \alpha)) = E_{X^*}(x(\alpha)), \quad (18)$$

où $u(s; \alpha) = F_s^{-1}(\alpha)$ désigne le seuil marginal d'ordre α à la position s , $x(\alpha) = \frac{1}{1-\alpha}$ le quantile d'ordre α de la loi $\text{Pa}(1)$, et où les ensembles d'excursion sont définis par

$$E_X(u(\cdot; \alpha)) = \{s \in D : X(s) > u(s; \alpha)\}, \quad E_{X^*}(x(\alpha)) = \{s \in D : X^*(s) > x(\alpha)\}.$$

Démonstration. Déterminons d'abord le quantile $x(\alpha)$. Puisque $X^*(s) \sim \text{Pa}(1)$, sa fonction de survie s'écrit $\mathbb{P}(X^*(s) > x) = x^{-1}$ pour $x \geq 1$. Le quantile d'ordre α est donc caractérisé par

$$\mathbb{P}(X^*(s) > x(\alpha)) = 1 - \alpha \iff x(\alpha) = \frac{1}{1 - \alpha}.$$

Ce quantile ne dépend pas de s : la transformation marginale a bien éliminé l'hétérogénéité spatiale des lois marginales.

Fixons à présent $s \in D$ et établissons l'équivalence entre les deux dépassements de seuil. Comme $F_s(X(s)) \in [0, 1[$ presque sûrement, les deux membres des inégalités ci-dessous sont strictement positifs, ce qui autorise le passage à l'inverse :

$$\begin{aligned} X^*(s) > x(\alpha) &\iff \frac{1}{1 - F_s(X(s))} > \frac{1}{1 - \alpha} \\ &\iff 1 - F_s(X(s)) < 1 - \alpha \quad (\text{inversion, membres strictement positifs}) \\ &\iff F_s(X(s)) > \alpha \\ &\iff X(s) > F_s^{-1}(\alpha) = u(s; \alpha). \quad (F_s \text{ continue et strictement croissante}) \end{aligned}$$

La dernière équivalence résulte de la stricte croissance de F_s , qui garantit que F_s^{-1} est bien définie et que $F_s(y) > \alpha \iff y > F_s^{-1}(\alpha)$.

On a ainsi montré que, pour tout $s \in D$,

$$s \in E_{X^*}(x(\alpha)) \iff s \in E_X(u(\cdot; \alpha)),$$

ce qui établit l'égalité (18). □

À l'aide de la transformation marginale de Pareto, on montre que l'ensemble d'excursion $E_X(U(\alpha)) = \{s \in D : X(s) > U(\alpha)\}$ égale presque partout à $E_{X^*}(x(\alpha)) = \{s \in D : X^*(s) > x(\alpha)\}$, où $x(\alpha)$ désigne le seuil constant de X^* au niveau α .

Données réelles Pour chaque date, on essaie de comparer l'ensemble d'excursion de X pour le seuil spatial et celle de $X^*(s)$ pour le seuil constant, tous les deux seuils sont en le même niveau 95%, comme présenté dans la figure 9. On met le graphe de ces deux ensembles d'excursion en parallèle, par conséquent on trouve que les deux graphes sont très similaires et la différence entre E_X et E_{X^*} ne porte que sur quelques points, donc on dit qu'ils sont égaux presque partout.

Ce qui illustre que la transformation de X vers $X^*(s)$ évite l'infection de localisation.

6.4 Volume de l'ensemble d'excursion E_{X^*} en fonction du seuil

Revenons sur la section 5.2.2, où nous n'avions pas pu terminer l'étude du volume de l'ensemble d'excursion E_x en fonction du seuil spatial. La figure 10 montre que le volume d'excursion de X^* pour le seuil constant est très proche de la fonction de survie $1/x$ d'une loi de Pareto(1). Ce résultat est cohérent avec la distribution attendue de X^* .




FIGURE 10 – Comparaison du volume d’excursion de X^* avec la fonction de survie théorique $1/x$ d’une loi de Pareto(1).

7 Évolution temporelle d’une qualité géométrique

Dans la section 6.3, nous avons prouvé que l’ensemble d’excursion de la transformation X^* pour un seuil constant est égal à celui de X pour le seuil spatial.

Nous avons affiché au chapitre 4 la représentation 3D de l’ensemble d’excursion. Afin d’étudier ce solide, nous le découpons en tranches pour chaque $t \in [0, T]$, ce qui permet d’introduire, sur l’intervalle $[0, T]$, les séries temporelles du de *l’aire*, du *périmètre*, du *rayon du plus grand disque inscrit dans l’ensemble d’excursion* et *nombre de composantes connexes* dans la section 3.3.

7.1 Extraction des séries temporelles

Pour chaque $t \in \{0, \dots, T\}$, l’ensemble d’excursion associé au champ transformé X^* et au seuil x est défini par

$$E_{X^*}(x, t) = \{s \in D : X^*(s, t) > x\}.$$

Quatre séries temporelles en sont extraites : l’aire $(A_t)_{1 \leq t \leq n}$, le périmètre $(P_t)_{1 \leq t \leq n}$, le rayon du plus grand disque inscrit $(R_t)_{1 \leq t \leq n}$ et le nombre de composantes connexes $(C_t)_{1 \leq t \leq n}$, avec la convention qu’elles valent zéro lorsque $E_{X^*}(x, t) = \emptyset$.

7.2 Test de stationnarité

Nous observons que les séries temporelles extraites présentent un comportement relativement régulier au cours du temps, sans tendance marquée apparente, comme présenté dans la figure 11. Nous souhaitons donc tester formellement leur stationnarité, propriété essentielle pour la modélisation ultérieure de ces séries.

Tests ADF et KPSS Nous utilisons conjointement les deux tests classiques de stationnarité en temps présentés dans la section 3.5.

Le test de *Dickey-Fuller augmenté* (ADF) teste si la série soit stationnaire. Ses hypothèses s’écrivent :

$$H_0 : \text{la série est non stationnaire} \quad \text{contre} \quad H_1 : \text{la série est stationnaire.}$$

Le test *KPSS* (*Kwiatkowski-Phillips-Schmidt-Shin*) adopte la formulation inverse :

$$H_0 : \text{la série est stationnaire} \quad \text{contre} \quad H_1 : \text{la série est non stationnaire.}$$




FIGURE 11 – Séries temporelles des quatre caractéristiques géométriques de l’ensemble d’excursion pour les mois de juin, juillet et août de chaque année.

Les conclusions concordantes de tests ADF et KPSS indiquent la stationnarité, cela permet une validation plus robuste.

TABLE 2 – Résultats des tests de stationnarité ADF et KPSS pour les quatre séries temporelles (niveau de significativité $\alpha = 0,05$).

Série	ADF			KPSS			Conclusion
	Stat.	p -valeur	H_0 rejetée	Stat.	p -valeur	H_0 rejetée	
Aire	-8,880	< 0,01	oui	0,315	> 0,1	non	stationnaire
Périmètre	-9,364	< 0,01	oui	0,319	> 0,1	non	stationnaire
Composantes connexes	-13,227	< 0,01	oui	0,245	> 0,1	non	stationnaire
$R_{\max}$	-9,287	< 0,01	oui	0,278	> 0,1	non	stationnaire

Le tableau 2 présente les résultats des deux tests pour les quatre séries. Pour chacune d’elles, le test ADF rejette l’hypothèse H_0 tandis que le test KPSS ne rejette pas l’hypothèse H_0 : les deux tests concordent, et nous concluons que les quatre séries sont stationnaires.

Cela confirme également la validité de l’hypothèse formulée dans la section 5.1.

7.3 Choix du modèle

Les quatre séries étant stationnaires, nous pouvons maintenant chercher un modèle adapté à leur dynamique, dans la classe des processus stationnaires classiques. Nous commençons par examiner si un modèle autorégressif (AR) convient.

La série du nombre de composantes connexes est exclue, car elle est à valeurs entières et incompatible avec les modèles AR classiques à bruit gaussien. L’analyse porte donc sur les trois séries continues : l’aire, le périmètre et le rayon maximal. Les modèles de comptage adaptés pour les séries du nombre de composantes connexes (Ex. INAR, Poisson) ne sont pas étudiés ici.

7.3.1 Modèle AR

Rappelons qu'un processus (X_t) suit un modèle autorégressif d'ordre p , noté $AR(p)$, s'il vérifie

$$X_t = c + \sum_{i=1}^p \varphi_i X_{t-i} + \varepsilon_t,$$

où c est une constante, $\varphi_1, \dots, \varphi_p$ sont les coefficients autorégressifs et (ε_t) est un bruit blanc de variance σ^2 .

ACF et PACF Pour déterminer l'ordre p d'un modèle AR, nous analysons les fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (PACF) empiriques. Un processus $AR(p)$ présente une ACF à décroissance progressive et une PACF qui s'annule au-delà du retard p , ce dernier permettant ainsi d'identifier l'ordre du modèle.

La figure 12a montre que, pour les trois séries (aire, périmètre et rayon maximal), l'ACF décroît progressivement et devient non significative après environ cinq à six retards. La figure 12b indique qu'un seul premier retard est significativement non nul, les autres valeurs restant majoritairement dans l'intervalle de confiance à 95 %.

Ce comportement est caractéristique d'un processus $AR(1)$. Nous retenons donc $p = 1$, qui sera confirmé par les critères d'information.




FIGURE 12 – Fonctions d'autocorrélation (à gauche) et d'autocorrélation partielle (à droite) des séries géométriques

AIC et BIC Afin de compléter l'analyse basée sur la PACF, nous ajustons des modèles $AR(p)$ pour $p = 0, \dots, 10$ et comparons les critères AIC et BIC :

$$AIC(p) = -2 \ell(\hat{\theta}_p) + 2(p + 1), \quad BIC(p) = -2 \ell(\hat{\theta}_p) + (p + 1) \ln n.$$

Ces critères permettent d'évaluer le compromis entre qualité d'ajustement et complexité du modèle.

La figure 13 montre que, pour les trois séries, l'AIC et le BIC diminuent continûment jusqu'à $p = 10$. Les critères d'information ne permettent donc pas d'identifier un minimum dans l'intervalle étudié. Cependant, l'analyse des ACF et PACF fait apparaître un coude autour de $p = 1$, ce qui suggère qu'un modèle $AR(1)$ fournit déjà une représentation raisonnable de la dépendance temporelle. Des modèles d'ordre plus élevé pourraient améliorer l'ajustement, mais au prix d'une complexité supplémentaire. Dans notre cas, nous retenons donc le modèle $AR(1)$.




FIGURE 13 – Les critères AIC et BIC

7.3.2 Extremogramme : Probabilité d'excursion conditionnelle

Les analyses précédentes caractérisent la dépendance temporelle globale des séries. Nous nous intéressons maintenant plus spécifiquement aux valeurs extrêmes. Lorsqu'une grande vague de chaleur est observée en France au jour t , nous cherchons à évaluer sa persistance h jours plus tard. L'autocorrélation classique ne décrit pas directement la dépendance dans les queues de distribution. Nous utilisons donc l'extremogramme introduit par Davis et Mikosch [6], formulé ici à partir de la probabilité d'excursion conditionnelle $p(h, \alpha)$.

Cadre mathématique Soit $(A_t)_{1 \leq t \leq n}$ la série temporelle stationnaire d'une fonctionnelle géométrique de l'ensemble d'excursion — nous présentons ici le cas de l'aire, l'analyse étant identique pour les autres séries. Pour un niveau $\alpha \in (0, 1)$, on définit le quantile d'ordre α de la loi marginale de A_t :

$$a_\alpha = q_\alpha(A_t) = \inf\{x \in \mathbb{R} : \mathbb{P}(A_t \leq x) \geq \alpha\}, \quad (19)$$

La probabilité de persistance au retard h est alors définie par

$$p(h, \alpha) = \mathbb{P}(A_{t+h} > a_\alpha \mid A_t > a_\alpha), \quad h \geq 1. \quad (20)$$

Cette quantité s'interprète comme la probabilité qu'un épisode extrême observé au jour t le demeure h jours plus tard.

Le cas indépendant fournit une valeur de référence : si la suite (A_t) est i.i.d., le conditionnement dans (20) est sans effet et

$$p(h, \alpha) = \mathbb{P}(A_{t+h} > a_\alpha) = 1 - \alpha \quad \text{pour tout } h \geq 1. \quad (21)$$

La valeur $p(h, \alpha) > 1 - \alpha$ signifie donc une dépendance temporelle positive dans les extrêmes, c'est-à-dire une tendance des dépassements à se regrouper en épisodes persistants.

Estimateur empirique À partir de la série observée $(A_t)_{1 \leq t \leq n}$, nous estimons $p(h, \alpha)$ par le rapport des fréquences empiriques

$$\hat{p}(h, \alpha) = \frac{\frac{1}{n-h} \sum_{t=1}^{n-h} \mathbf{1}\{A_{t+h} > \hat{a}_\alpha, A_t > \hat{a}_\alpha\}}{\frac{1}{n} \sum_{t=1}^n \mathbf{1}\{A_t > \hat{a}_\alpha\}}, \quad (22)$$

où $\hat{a}_\alpha = \hat{q}_\alpha(A_t, t = 1, \dots, n)$ désigne le quantile empirique d'ordre α de l'échantillon.

La série étant restreinte aux étés (juin–août), nous excluons des sommes de (22) les paires $(t, t+h)$ qui traverse deux étés, seules les paires séparées d'exactly h jours calendaires étant retenues.




FIGURE 14 – Extremogramme estimé du champ transformé Y^* pour les données de températures estivales entre 1986 et 2005. La figure représente la probabilité d'excursion conditionnelle $\hat{p}(h, \alpha)$ en fonction du retard temporel h et du niveau α .

La figure 14 représente l'estimation empirique de la probabilité d'excursion conditionnelle $\hat{p}(h, \alpha)$ associée à la série d'aire A_t , pour des décalages temporels h allant de 1 à 15 jours et des niveaux α compris entre 0,1 et 0,98.

Pour les niveaux faibles à modérés ($\alpha \lesssim 0,6$), les lignes de niveau sont presque verticales. La probabilité conditionnelle décroît progressivement, d'environ 0,75 pour $h = 1$ à 0,55 pour $h \approx 8$, puis se stabilise autour de cette valeur jusqu'à $h = 15$. La dépendance temporelle de la série est donc forte et persistante, une journée de forte aire d'excursion est très probablement suivie de journées comparables, et cette mémoire ne s'éteint que lentement.

Le comportement change en revanche pour les niveaux élevés ($\alpha \gtrsim 0,7$) : à décalage fixé, $\hat{p}(h, \alpha)$ diminue sensiblement lorsque α augmente, et les lignes de niveau deviennent essentiellement horizontales. La persistance des excursions les plus extrêmes est ainsi plus faible que celle des excursions ordinaires : au-delà de $\alpha = 0,9$, la probabilité de dépassement conditionnelle chute en dessous de 0,3 dès $h = 2$, puis en dessous de 0,1 pour les grands décalages. Ce résultat est cohérent avec la durée typique des épisodes de canicule : la persistance à court terme (de l'ordre de 1 à 4 jours) reste marquée même aux niveaux élevés, tandis que la dépendance à plus long terme s'estompe rapidement.

Il convient enfin de noter que les estimations situées dans le coin supérieur droit du graphique (grands h et α proches de 1) reposent sur un très petit nombre de dépassements : les irrégularités des lignes de niveau dans cette région traduisent avant tout la variabilité d'échantillonnage, et ces valeurs doivent être interprétées avec prudence.

8 QQ plot

Bien que nous ayons bien étudié l'ensemble d'excursion, nous proposons à présent une analyse complémentaire fondée sur les QQ-plots, afin de vérifier empiriquement si les données réelles de X^* suivent bien la loi de Pareto, comme établi théoriquement. Au-delà de cette validation, le QQ-plot offre un nouveau point de vue : il permet d'évaluer la probabilité d'occurrence de températures extrêmes, et de classer les zones présentant une tendance similaire d'un été à l'autre.

8.1 Vérification la lois de $X^*(s)$

Rappelons que la transformation X^* est défini par

$$X^*(s) = \frac{1}{1 - F_s(X(s))}$$

où $F_s(x) = \mathbb{P}(X(s) \leq x)$ la fonction de répartition de $X(s)$, $s \in D$. Nous cherchons à présent à vérifier si la variable transformée $X^*(s)$ suit une loi de Pareto standard (Pareto(1)). Pour ce faire, nous analysons un QQ plot pour une station choisie au hasard.

La méthodologie se déroule en trois étapes :

- Dans un premier temps, la fonction de répartition empirique $\widehat{F_{X(s)}}$ est estimée à partir de l'historique des données de vingt étés (1986-2005).
- Ensuite, nous évaluons les observations d'une année cible au travers de cette fonction $\widehat{F_{X(s)}}$ afin d'obtenir la série des valeurs transformées $X^*(s)$ pour cette année spécifique.
- Enfin, nous construisons le QQ-plot en plaçant en abscisse les quantiles théoriques de la loi Pareto(1), et en ordonnée les quantiles empiriques calculés sur les $X^*(s)$. Nous superposons au nuage de points la diagonale $y = x$, correspondant à l'ajustement parfait, ainsi que la droite de régression ajustée sur les points, afin d'évaluer visuellement la qualité de l'ajustement au modèle théorique.

Pour illustrer la démarche, nous sélectionnons aléatoirement un site s de la grille, ainsi que cinq étés parmi la période d'étude, et nous traçons le QQ-plot correspondant. Sur l'échelle naturelle, le graphique n'est pas très bien lisible : la loi de Pareto étant à queue lourde, la majorité des quantiles se concentre dans les petites valeurs, tandis que quelques observations extrêmes étirent l'échelle et écrasent le reste du nuage de points.

Pour mieux visualiser le comportement de la queue lorsqu'on s'approche des valeurs extrêmes, on transforme la variable $X^*(s)$ en $Z = \log X^*(s)$. Alors la fonction de répartition de Z est donnée par

$$\begin{aligned} \mathbb{P}(Z \leq z) &= \mathbb{P}(\log X^*(s) \leq z) \\ &= \mathbb{P}(X^*(s) \leq e^z) \\ &= 1 - \frac{1}{e^z} \quad \text{car } X^*(s) \sim \text{Pa}(1) \\ &= 1 - e^{-z} \end{aligned}$$

ce qui correspond à la fonction de répartition exponentielle.

Donc sa fonction de quantile s'écrit comme

$$q_\alpha = -\log(1 - \alpha)$$

donc on trace le QQ plot de $\log X^*(s)$ contre $Exp(1)$.

En échelle logarithmique, le nuage de points s'aligne nettement mieux sur la diagonale, sans toutefois s'y superposer parfaitement. Cet écart résiduel n'est pas surprenant : la loi de Pareto théorique décrit le comportement moyen sur l'ensemble de la période, alors que chaque été possède sa propre intensité thermique.




FIGURE 15 – Localisation spatiale du point sélectionné et QQ-plots de la variable transformée Z pour les différentes années étudiées.

8.2 La tendance de la température chaque été

Ayant donné des QQ-plots, nous observons que l'écart à la diagonale porte ainsi une information climatique interprétable : lorsque la droite de régression (ou le nuage de points) se situe au-dessus de la diagonale, les quantiles empiriques dépassent les quantiles théoriques, ce qui correspond à un été plus chaud que la référence ; à l'inverse, une position en dessous de la diagonale traduit un été plus froid.

Cette observation nous conduit à utiliser le QQ-plot non plus seulement comme un outil de validation, mais comme un instrument de diagnostic annuel. Pour un été donné, nous relierons les points du QQ-plot de chaque site afin d'obtenir une courbe quantile-quantile, puis nous superposons sur un même graphique les courbes de 1000 sites tirés aléatoirement sur la grille. La position d'ensemble de ce faisceau de courbes par rapport à la diagonale révèle alors la tendance globale de l'été considéré : un faisceau majoritairement au-dessus de la diagonale signale un été chaud à l'échelle nationale, tandis qu'un faisceau en dessous indique un été frais ; un faisceau réparti de part et d'autre de la diagonale correspond quant à lui à un été sans anomalie particulière.




FIGURE 16 – Comparaison des distributions des température de chaque année. Chaque graphique représente un échantillon de 1000 stations spatiales.

8.3 Validation hors échantillon et classification des étés de test

Les analyses précédentes reposent sur une fonction de répartition F_s estimée à partir de l'ensemble de la période d'étude. Pour tester la stabilité de cette transformation marginale sur de nouvelles données, nous utilisons également une validation hors échantillon. La période d'étude est ainsi divisée en deux sous-ensembles :

- une période d'histoire ($train(80\%)$), constituée des étés de 1986 à 2001, sur laquelle nous estimons, pour chaque position s , la fonction de répartition empirique historique $\hat{F}_s^{hist}$;
- une période de future ($test(20\%)$), constituée des étés de 2002 à 2005, dont les températures sont transformées à l'aide de $\hat{F}_s^{hist}$.

Pour chaque été de la période de test et chaque position s , nous appliquons X puis nous construisons le QQ-plot en échelle logarithmique comparant les quantiles empiriques de l'été de test aux quantiles théoriques de la loi Pareto(1). La position du nuage de points par rapport à la diagonale mesure alors l'écart entre le comportement thermique de l'été considéré et la référence historique : un nuage situé au-dessus de la diagonale indique des températures plus élevées que celles de la période d'apprentissage, et inversement.


Règle de classification. Afin de systématiser cette lecture visuelle, nous classons chaque site en trois catégories à partir des résidus signés du QQ-plot. Pour un site s et un été de test donnés, notons $(q_i^{th}, q_i^{emp})_{1 \leq i \leq n}$ les couples de quantiles en échelle logarithmique, et définissons les résidus

$$r_i = q_i^{emp} - q_i^{th}, \quad 1 \leq i \leq 92.$$


Le signe de chaque résidu est déterminé à une tolérance numérique $\varepsilon = 10^{-5}$ près : le résidu r_i est compté comme positif si $r_i > \varepsilon$, négatif si $r_i < -\varepsilon$, et considéré comme nul sinon. Notons π^+ (respectivement π^-) la proportion de résidus positifs (respectivement négatifs). La classification s'effectue selon la règle suivante :

- si $\pi^+ \geq 0,9$, le site est classé *chaud* (rouge) : la plupart des quantiles empiriques dépasse la référence historique, et ils sont en-dessus de la diagonale ;
- si $\pi^- \geq 0,9$, le site est classé *froid* (bleu) : les quantiles empiriques sont presque inférieurs à la référence, et ils sont en-dessous de la diagonale ;
- dans tous les autres cas, le site est classé *neutre* (orange) : le nuage de points se répartit de part et d'autre de la diagonale, sans écart systématique, ce qui traduit un comportement conforme à la référence historique.


Le seuil de 90% permet de classer un site comme chaud ou froid lorsque les écarts ont majoritairement le même signe. La tolérance ε évite de considérer comme positifs ou négatifs les résidus très proches de zéro. Cette classification est appliquée à chaque site afin de cartographier, pour chaque été de test, les zones plus chaudes, plus froides ou proches de la référence historique.




Année 2002. Les quantiles de test sont majoritairement inférieurs à ceux de l’histoire, traduisant une année globalement plus fraîche.



Année 2003. Les quantiles de test sont majoritairement supérieurs à ceux de l’histoire, traduisant une année globalement plus chaude.



Année 2004. Les régions du nord sont globalement plus chaudes, tandis que le sud reste proche de l’histoire, avec quelques stations plus froides.



Année 2005. Le comportement reste proche de l’histoire, avec quelques stations du sud présentant des températures légèrement plus faibles.

FIGURE 17 – Validation temporelle des séries de température entre la période d’histoire (1986–2001) et les années de future (2002–2005).

9 Pipeline pour une autre variable : les précipitations

L'objectif de ce chapitre est d'évaluer la pertinence de l'approche proposée sur un nouveau jeu de données.

Nous téléchargeons des données de précipitations provenant du même site et issues du même modèle. Nous sélectionnons les données de précipitations sur la France métropolitaine pour les mois d'octobre et de novembre, entre les années 1986 et 2005. Soit $Y : \mathbb{R}^2 \times [0, T] \times \Omega \rightarrow \mathbb{R}$ un champ aléatoire défini sur $\mathbb{R}^2 \times [0, T]$. Soit $D \subset \mathbb{R}^2$ un sous-ensemble représentant le domaine spatial, et $[0, T] \subset \mathbb{R}$ un intervalle de temps représentant la période d'observation, où T correspond au nombre de jours observés.

9.1 L'ensemble d'excursion de Y en deux dimensions

Nous nous concentrons tout d'abord sur l'analyse spatiale du champ aléatoire Y à travers l'étude de ses ensembles d'excursion en dimension deux. Les ensembles correspondant à différents niveaux de seuil sont visualisés, puis leurs propriétés géométriques sont caractérisées à l'aide de plusieurs indicateurs descriptifs.

9.2 Séries temporelle de Y^*

Dans un second temps, nous analysons la structure temporelle du champ en considérant les séries temporelles associées aux différents points spatiaux. Afin d'approfondir l'étude des événements extrêmes, une transformation vers marges de Pareto standard du champ Y , notée Y^* , est introduite. Les séries temporelles transformées (voir la figure 19) sont ensuite soumises à des tests de stationnarité. Les résultats obtenus indiquent que les séries temporelles de Y^* sont toutes stationnaires.






FIGURE 18 – L'ensemble d'excursion de Y et Y^*


Nous étudions ensuite la dépendance temporelle des séries transformées à l'aide des fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (PACF). Bien que ces analyses suggèrent une structure de dépendance de faible ordre, notamment un comportement compatible avec un modèle autorégressif d'ordre proche de $p = 1$, la comparaison des critères de AIC et de BIC pour différents ordres autorégressifs ne permet pas d'identifier un ordre optimal clairement déterminé. En effet, les valeurs des critères continuent de diminuer lorsque l'ordre du modèle augmente, ce qui rend le choix de p non concluant dans la plage étudiée.




(a) Nombre de composantes connexes



(b) Aire




(c) Périmètre




(d) Rayon du plus grand disque inscrit


FIGURE 19 – Séries temporelles des quatre caractéristiques géométriques de l'ensemble d'excursion pour les mois d'octobre et de novembre de chaque année.



(a) ACF



(b) PACF

 FIGURE 20 – Autocorrelation and partial autocorrelation functions of the transformed field Y^* .

 FIGURE 21 – Evolution of AIC and BIC criteria for autoregressive models $AR(p)$ with different orders p .




FIGURE 22 – Extremogramme estimé du champ transformé Y^* pour les données de précipitations entre 1986 et 2005. La figure représente la probabilité d'excursion conditionnelle $\hat{\rho}(h, \alpha)$ en fonction du retard temporel h et du niveau α .

Enfin, afin d'analyser plus spécifiquement la dépendance des événements extrêmes, l'extremogramme est calculé et représenté graphiquement.

Dans cette étude, l'extremogramme est calculé à partir de l'aire de l'ensemble d'excursion de Y^* .

La figure 22 présente l'estimation de l'extremogramme associé à l'aire d'excursion de Y^* , pour différents niveaux α et des retards temporels h variant de 1 à 15 jours. Il représente la probabilité conditionnelle d'observer une grande aire d'excursion au temps $t + h$, sachant qu'une grande aire a été observée au temps t .

Pour les faibles valeurs de α , les probabilités diminuent peu lorsque le retard h augmente. En revanche, lorsque α augmente, la diminution avec h devient plus marquée. Cela indique une dépendance temporelle qui s'atténue progressivement avec le temps.

Pour un niveau α fixé, on observe également une diminution globale de l'extremogramme lorsque le retard h augmente, principalement pour les premiers jours. La dépendance temporelle de l'aire des excursions est donc plus marquée à court terme.

9.3 QQ plot et validation hors échantillon

Afin de comparer les distributions empirique et théorique, nous construisons un QQ-plot entre les quantiles empiriques de $\log(Y^*)$ et les quantiles théoriques de la loi exponentielle $\text{Exp}(1)$. Nous constatons que les données empiriques contiennent un grand nombre de valeurs faibles, ce qui peut influencer la représentation graphique et masquer le comportement de la queue de distribution. Afin de nous concentrer sur les valeurs extrêmes, nous introduisons un seuil défini comme le quantile d'ordre 0.5 de l'ensemble des observations de Y^* :

$$z_0 = \hat{q}_{0.5}(Y^*).$$

Les observations inférieures à ce seuil sont alors exclues, et seules les valeurs satisfaisant $Y^* > z_0$ sont conservées pour l'analyse. Ensuite, une transformation logarithmique centrée par le seuil est appliquée :

$$Z' = \log(Y^*) - \log(z_0)$$

pour les observations vérifiant $Y^* > z_0$. Cette transformation permet d'obtenir une variable Z' dont le comportement théorique est celui d'une loi exponentielle $\text{Exp}(1)$ dans le cadre considéré. Afin de justifier cette transformation, considérons une variable Y^* suivant une loi de Pareto de paramètre 1, dont la fonction de survie est donnée par

$$\mathbb{P}(Y^* > y) = \frac{1}{y}, \quad y \geq 1.$$

Soit z_0 un seuil fixé et considérons uniquement les observations vérifiant $Y^* > z_0$. On définit alors la variable centrée

$$Z' = \log(Y^*) - \log(z_0) = \log\left(\frac{Y^*}{z_0}\right).$$

Pour tout $z \geq 0$, la fonction de survie conditionnelle de Z' s'écrit

$$\mathbb{P}(Z' > z) = \mathbb{P}(\log(Y^*) - \log(z_0) > z \mid Y^* > z_0) \quad (23)$$

$$= \mathbb{P}(Y^* > z_0 e^z \mid Y^* > z_0) \quad (24)$$

$$= \frac{\mathbb{P}(Y^* > z_0 e^z)}{\mathbb{P}(Y^* > z_0)}. \quad (25)$$

En utilisant la propriété de la loi de Pareto,

$$\mathbb{P}(Y^* > z_0 e^z) = \frac{1}{z_0 e^z}, \quad \mathbb{P}(Y^* > z_0) = \frac{1}{z_0},$$

on obtient alors

$$\mathbb{P}(Z' > z) = \frac{1/(z_0 e^z)}{1/z_0} = e^{-z}.$$

Or, e^{-z} est précisément la fonction de survie d'une loi exponentielle de paramètre 1. Ainsi,

$$Z' \sim \text{Exp}(1).$$




FIGURE 23 – Localisation spatiale du point sélectionné et QQ-plots de la variable transformée Z' pour les différentes années étudiées.

Enfin, la robustesse de l'approche est évaluée à travers une validation hors échantillon. Les données de test sont utilisées afin d'analyser les performances de classification des événements extrêmes et de vérifier la capacité du modèle à généraliser sur des observations indépendantes.

Les stations en rouge correspondent à des conditions moins pluvieuses, celles en bleu à des conditions plus pluvieuses, et celles en jaune à des précipitations comparables à celles de l'histoire. On observe une répartition spatiale des couleurs plus dispersée que pour les données de température. De plus, la proportion de stations jaunes est plus importante, ce qui indique que les précipitations présentent plus souvent un comportement similaire entre les périodes du passé et de la future.




FIGURE 24 – Validation de la classification entre les périodes du passé et de la future pour les données de précipitation.

10 Conclusion et perspectives

Ce stage a permis d'étudier la structure spatio-temporelle d'un champ aléatoire en se concentrant sur l'analyse des événements extrêmes. Nous avons construit une grille régulière permettant d'analyser les ensembles d'excursion sur la carte. Par ailleurs, les tests de stationnarité, l'étude de la dépendance temporelle à l'aide de l'ACF et de la PACF, les critères de AIC et BIC, ainsi que le calcul de l'extremogramme, sont appliqués aux les séries temporelles. À noter que pour la série du nombre de composantes connexes, nous étudions seulement les tests de stationnarité car elle prend ses valeurs dans $\mathbb{N}$, donc n'est pas adapté d'ajuster un modèle $AR(p)$. À part les études des ensembles d'excursion, nous avons également analysé des QQ-plots afin d'évaluer le caractère extrême des observations. Après l'analyse des données de température, la même approche a été appliquée à des données de précipitation afin de vérifier si les méthodes utilisées peuvent être adaptées à d'autres types de données.

Une perspective de ce travail concerne l'application des outils développés pendant le stage à des modèles spatio-temporels simulés. Dans les travaux actuellement effectués par Anne Estrade et José Gregorio Gomez Garcia, un modèle séparable de la forme

$$X(s, t) = \Lambda(t)W(s)$$

est considéré, où $\Lambda(t)$ est un processus temporel de type shot noise et $W(s)$ un champ aléatoire gaussien stationnaire. Pour un seuil fixé, ce modèle permet de construire des ensembles d'excursion et d'étudier l'évolution temporelle de leurs indicateurs géométriques, par exemple l'aire, le périmètre, le nombre de composantes connexes et le caractéristique d'Euler en plus (voir Figure 26). Les ensembles d'excursion obtenus par différentes valeurs de paramètres de $\Lambda(t)$ et de $W(s)$ montrent des configurations spatiales (voir Figure 25). Ces simulations est un cadre naturel pour prolonger le travail réalisé pendant ce stage, en appliquant les mêmes outils d'analyse géométrique à un modèle plus précis.




FIGURE 25 – Exemples d'ensembles d'excursion du champ $X(s, t)$ pour différents instants t . Pour chaque réalisation, la valeur de $\Lambda(t)$ et l'aire de l'ensemble d'excursion sont indiquées.




FIGURE 26 – Évolution temporelle du processus $\Lambda(t)$ et des caractéristiques géométriques des ensembles d'excursion : aire, périmètre, nombre de composantes connexes en 4-connexité et caractéristique d'Euler.

Références

- [1] Cotsakis, R. Di Bernardino, E., Opitz, T., (2024) *On the spatial extent of extreme threshold exceedances*,
Arxiv : <https://arxiv.org/abs/2411.02399>
- [2] Cotsakis, R. Di Bernardino, E., Opitz, T., (2026) *Assessing the size of spatial extreme events using local coefficients based on excursion sets*, Spatial Statistics. Volume 72. 2026.
- [3] Di Bernardino, E., Estrade, A. and Opitz, T., (2024) *Spatial extremes and stochastic geometry for Gaussian-based peaks-over-threshold processes*, Extremes, 27, 397–435.
- [4] Dickey, D. A., Fuller, W. A., (1979) *Distribution of the Estimators for Autoregressive Time Series with a Unit Root*,
Journal of the American Statistical Association, 74(366), 427–431.
- [5] Kwiatkowski, D., Phillips, P. C. B., Schmidt, P., Shin, Y., (1992) *Testing the Null Hypothesis of Stationarity Against the Alternative of a Unit Root*,
Journal of Econometrics, 54(1–3), 159–178.
- [6] Davis, R. A., Mikosch, T., (2009) *The Extremogram : A Correlogram for Extreme Events*,
Bernoulli, 15(4), 977–1002.

Code et données

L'ensemble des codes utilisés pour le traitement des données, le calcul des caractéristiques géométriques et la production des figures est disponible dans le dépôt Github suivant :

<https://github.com/zding1501/>

Stage-Geometrie-des-ensembles-d-excursion-pour-l-analyse-des-extremes-spatiaux

En raison de leur volume, les données utilisées dans cette étude sont disponibles séparément sur Google Drive :

[https://drive.google.com/drive/folders/1pn6rDkmtR_9oWB_DSvAD0J-hu-94P0mT?
usp=sharing](https://drive.google.com/drive/folders/1pn6rDkmtR_9oWB_DSvAD0J-hu-94P0mT?usp=sharing)